LAPORAN EXPLORATORY DATA ANALYSIS (EDA)

Studi Kasus: Prediksi Kelulusan Tepat Waktu Mahasiswa

Dosen Pengampu : HENNY DWI BHAKTI, S.Si., M.Si.

RIYAN HIDAYAT (240602065)

KELAS B-PG

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS MUHAMMADIYAH GRESIK

1. Identitas dan Tujuan Dataset

Laporan ini menyajikan hasil Exploratory Data Analysis (EDA) terhadap dataset simulasi yang digunakan sebagai running case pembelajaran prediksi kelulusan tepat waktu mahasiswa. Tujuan analisis pada tahap ini adalah melakukan diagnosis data secara sistematis — memahami struktur, kualitas, distribusi, dan hubungan antarvariabel — sebelum data digunakan pada tahap preprocessing (Pertemuan 4) dan pemodelan Machine Learning.

1.1 Ringkasan Dataset

Atribut	Keterangan
Jumlah observasi	300 mahasiswa
Jumlah variabel	15 kolom (1 ID, 2 kategorikal, 11 numerik, 1 target)
Target	Status_Kelulusan (Tepat Waktu / Tidak Tepat Waktu)
Definisi target	Tepat Waktu = masa studi ≤ 8 semester; Tidak Tepat Waktu = masa studi > 8 semester
Feature utama	IP_Smt1–IP_Smt4, SKS_Smt1–SKS_Smt4, Jumlah_Mengulang, Jumlah_Nilai_DE, Kehadiran_Rata2, Jenis_Kelamin, Jalur_Masuk
Sifat data	Data sintetis/simulasi; beberapa masalah data sengaja disisipkan untuk latihan EDA

2. Pemeriksaan Struktur dan Kualitas Data

2.1 Struktur dan Tipe Data

Berdasarkan output data.info(), dataset terdiri dari 300 baris dan 15 kolom dengan tipe data sebagai berikut:

Tipe Data	Jumlah Kolom	Contoh Variabel
Categorical (object)	4	ID_Mahasiswa, Jenis_Kelamin, Jalur_Masuk, Status_Kelulusan
Numerical continuous (float64)	5	IP_Smt1–IP_Smt4, Kehadiran_Rata2
Numerical discrete (int64)	6	SKS_Smt1–SKS_Smt4, Jumlah_Mengulang, Jumlah_Nilai_DE

2.2 Missing Value

Pemeriksaan dengan data.isnull().sum() menemukan missing value pada dua variabel:

Variabel	Jumlah Missing	Persentase
IP_Smt2	6	2,0%
Kehadiran_Rata2	3	1,0%

Kedua kolom ini perlu ditangani melalui imputasi pada tahap preprocessing (P4). Tidak dilakukan pengisian atau penghapusan pada tahap EDA ini.

2.3 Invalid Value

Invalid value adalah nilai yang melanggar aturan/domain variabel, berbeda dengan outlier yang merupakan nilai ekstrem namun masih mungkin valid. Berdasarkan statistik deskriptif (data.describe()) dan pemeriksaan langsung, ditemukan:

A. IP_Smt1 = 4,75 pada observasi MHS0065 — melanggar domain IP yang seharusnya berada pada rentang 0–4,00.

B. Kehadiran_Rata2 = 125,0% pada observasi MHS0190 — melanggar domain persentase kehadiran yang valid maksimal 100%.

C. Kategori Jalur_Masuk tidak konsisten: ditemukan varian "regular" (1 observasi) dan "REG" (1 observasi) yang secara semantik merujuk pada kategori yang sama dengan "Reguler" (203 observasi), namun tertulis dengan format berbeda.

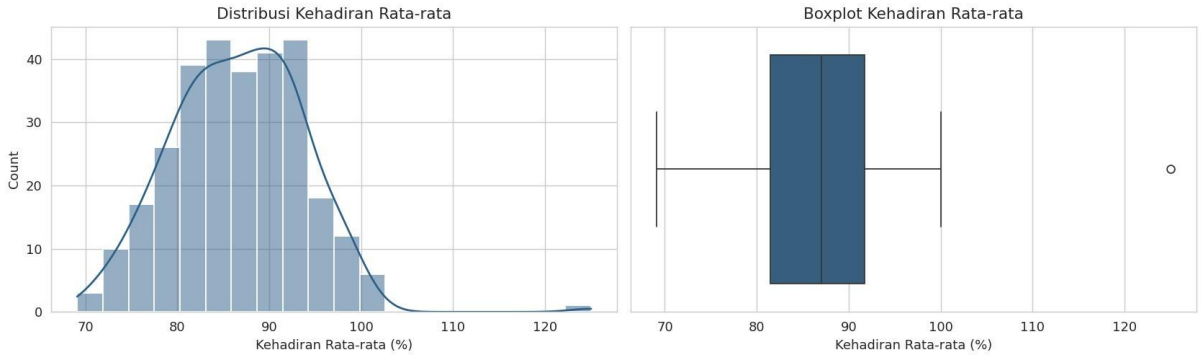
Ketiga jenis masalah di atas memerlukan penanganan berbeda pada tahap preprocessing: IP dan kehadiran invalid memerlukan investigasi/koreksi nilai, sedangkan kategori Jalur_Masuk memerlukan standardisasi penulisan (bukan penghapusan data).

2.4 Duplicate Data

Pemeriksaan dengan data.duplicated().sum() dan pengecekan ID_Mahasiswa unik menunjukkan tidak ditemukan baris duplikat pada dataset ini (0 dari 300 observasi).

3. Analisis Distribusi

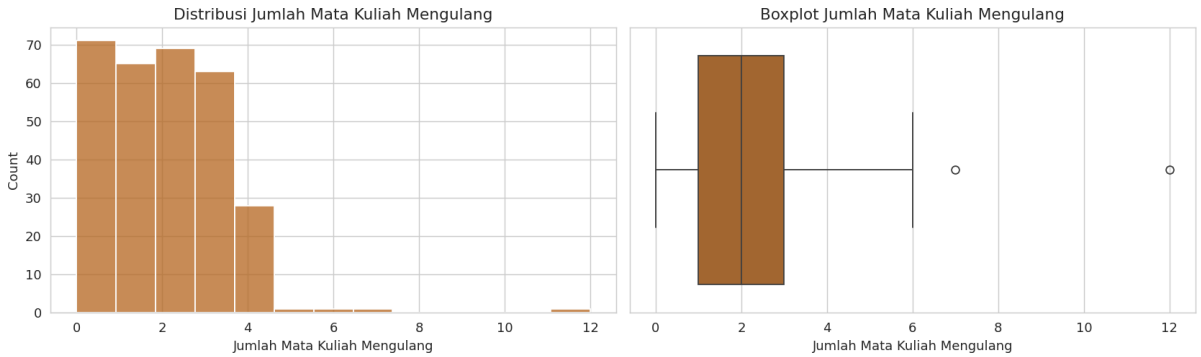
3.1 Distribusi Kehadiran Rata-rata



Gambar 1. Histogram dan boxplot Kehadiran Rata-rata mahasiswa

Histogram menunjukkan mayoritas nilai kehadiran terkonsentrasi pada rentang 75–95%, dengan bentuk distribusi mendekati simetris. Boxplot mengonfirmasi median berada di sekitar 87%, dengan kotak IQR pada rentang ±81–92%. Satu titik data pada 125% tampak jauh terpisah di ujung kanan dan berada jauh di luar whisker atas — titik ini merupakan invalid value yang telah diidentifikasi pada Bagian 2.3, bukan sekadar variasi alami data.

3.2 Distribusi Jumlah Mata Kuliah Mengulang



Gambar 2. Histogram dan boxplot Jumlah Mata Kuliah Mengulang

Distribusi Jumlah_Mengulang bersifat right-skewed: sebagian besar mahasiswa mengulang 0 hingga 3 mata kuliah, namun terdapat ekor panjang ke arah kanan. Dengan Q1 = 1, Q3 = 3, dan IQR = 2, batas atas outlier menurut aturan 1,5×IQR adalah 6. Dua observasi berada di luar batas ini: MHS0147 (7 kali mengulang) dan MHS0156 (12 kali mengulang).

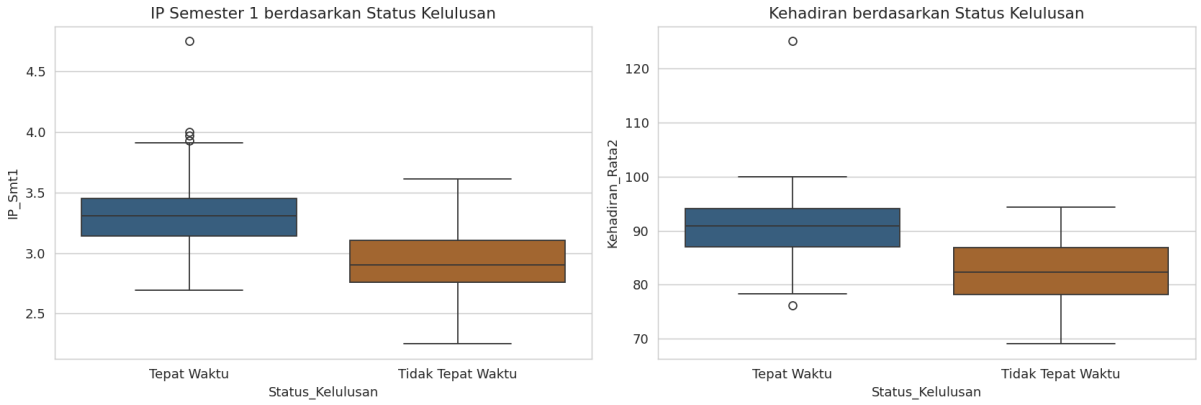
Investigasi lebih lanjut terhadap kedua kasus ekstrem menunjukkan karakteristik yang kontras: MHS0147 memiliki IP rendah (2,4–3,0), kehadiran rendah (77,7%), dan berstatus Tidak Tepat Waktu — konsisten dengan pola umum. Sebaliknya, MHS0156 (nilai paling ekstrem, 12 kali mengulang) justru memiliki IP relatif baik (3,3–3,8), kehadiran tinggi (96,9%), dan tetap berstatus Tepat Waktu. Hal ini menegaskan bahwa outlier tidak boleh langsung diasumsikan sebagai kasus "bermasalah" tanpa melihat konteks feature lain, dan bahwa satu feature saja jarang cukup untuk menjelaskan target.

4. Analisis Feature terhadap Target

Perbandingan rata-rata feature numerik utama antara kelompok Tepat Waktu dan Tidak Tepat Waktu (data.groupby("Status_Kelulusan").mean()) disajikan pada tabel berikut.

Feature	Tepat Waktu	Tidak Tepat Waktu
IP_Smt1	3,319	2,928
IP_Smt2	3,343	2,907
IP_Smt3	3,364	2,949
IP_Smt4	3,407	2,979
Jumlah_Mengulang	1,12	2,45
Jumlah_Nilai_DE	0,93	1,57
Kehadiran_Rata2 (%)	90,55	82,54

Pada dataset ini, kelompok Tepat Waktu cenderung memiliki IP di setiap semester yang lebih tinggi, jumlah mata kuliah mengulang dan nilai D/E yang lebih rendah, serta kehadiran rata-rata yang lebih tinggi dibandingkan kelompok Tidak Tepat Waktu. Pola ini konsisten di seluruh semester IP (1 hingga 4), mengindikasikan bahwa perbedaan performa akademik antar-kelompok bersifat stabil, bukan hanya terjadi pada satu titik waktu tertentu.



Gambar 3. Boxplot IP Semester 1 dan Kehadiran Rata-rata berdasarkan Status Kelulusan

Boxplot menunjukkan median IP Semester 1 dan Kehadiran pada kelompok Tepat Waktu berada lebih tinggi dibandingkan kelompok Tidak Tepat Waktu. Meski demikian, kedua kotak menunjukkan overlap yang cukup besar.

Sebagian mahasiswa dengan IP atau kehadiran rendah tetap berstatus Tepat Waktu, dan sebaliknya. Overlap ini menunjukkan bahwa IP Semester 1 atau kehadiran saja belum cukup memisahkan kedua kelas secara sempurna; kombinasi beberapa feature kemungkinan diperlukan pada tahap pemodelan.

5. Analisis Distribusi Target



Gambar 4. Distribusi Status Kelulusan

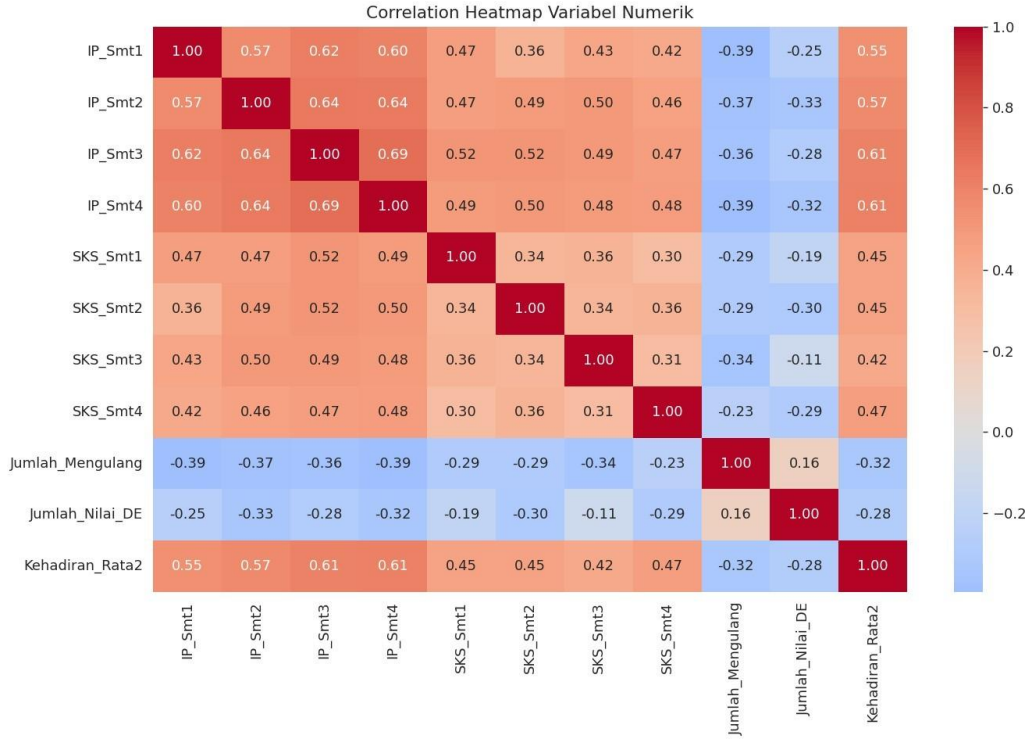
Kelas	Jumlah	Persentase
Tepat Waktu	152	50,7%
Tidak Tepat Waktu	148	49,3%

Distribusi target menunjukkan proporsi yang relatif seimbang, mendekati 50:50. Dengan demikian, tidak terdapat indikasi class imbalance yang signifikan pada dataset ini. Implikasinya, metrik accuracy pada tahap evaluasi model nanti dapat digunakan secara wajar sebagai salah satu indikator performa, karena risiko accuracy yang

menyesatkan akibat kelas mayoritas dominan (sebagaimana dicontohkan pada kasus proporsi 90:10 di materi kuliah) relatif kecil untuk dataset ini.

6. Analisis Korelasi

Correlation matrix dihitung menggunakan korelasi Pearson (data.corr()) terhadap seluruh variabel numerik. Status_Kelulusan tidak disertakan karena masih berupa data kategorikal.



Gambar 5. Correlation Heatmap Variabel Numerik

Tiga Hubungan Antarvariabel yang Menonjol

1. IP_Smt3 dengan IP_Smt4 (r ≈ 0,69) — korelasi positif kuat. Mahasiswa dengan IP tinggi pada satu semester cenderung mempertahankan IP tinggi pada semester berikutnya, menunjukkan konsistensi performa akademik antarwaktu.

2. Jumlah_Mengulang dengan IP semester 1–4 (r ≈ −0,36 s.d. −0,39) — korelasi negatif sedang. Mahasiswa dengan jumlah mata kuliah mengulang yang lebih banyak cenderung memiliki IP yang lebih rendah di seluruh semester.

3. Kehadiran_Rata2 dengan IP semester 1–4 (r ≈ 0,55–0,61) — korelasi positif sedang hingga kuat. Kehadiran yang lebih tinggi cenderung berasosiasi dengan IP yang lebih baik pada dataset ini.

Korelasi Tidak Sama dengan Kausalitas

Nilai korelasi yang ditemukan hanya menggambarkan pola hubungan linear antarvariabel pada dataset ini, dan tidak dapat langsung diartikan sebagai hubungan sebab-akibat. Sebagai contoh, korelasi negatif antara Jumlah_Mengulang dan IP tidak dapat disimpulkan sebagai "mengulang mata kuliah menyebabkan IP turun" hubungan tersebut bisa jadi dipengaruhi oleh faktor lain yang tidak tercatat dalam dataset (misalnya kesulitan adaptasi akademik, kondisi pribadi, atau beban kerja di luar kuliah) yang memengaruhi kedua variabel secara bersamaan. Kesimpulan kausal memerlukan desain penelitian dan bukti yang berbeda dari sekadar analisis korelasi deskriptif.

7. Kesimpulan EDA dan Rekomendasi Preprocessing

Berdasarkan seluruh tahap EDA yang telah dilakukan, dataset Prediksi Kelulusan Tepat Waktu Mahasiswa memiliki karakteristik dan masalah kualitas data sebagai berikut:

Temuan EDA	Bukti	Implikasi	Rencana P4
IP_Smt2 dan Kehadiran_Rata2 missing	6 dan 3 nilai kosong (isnull().sum())	Data belum lengkap	Imputation
IP_Smt1 = 4,75; Kehadiran = 125%	describe(), filter kondisi	Nilai melanggar domain	Investigasi/koreksi invalid value
Kategori Jalur_Masuk tidak konsisten	"regular", "REG" vs "Reguler"	Belum siap untuk encoding	Standardisasi kategori
Jumlah_Mengulang: 2 potential outlier (7, 12)	Aturan IQR, boxplot	Perlu verifikasi konteks	Investigasi lanjutan/treatment
Skala antarvariabel berbeda	IP 0–4 vs SKS 13–24 vs Kehadiran 0–100	Algoritma tertentu (mis. berbasis jarak) sensitif terhadap skala	Scaling/normalisasi
Target relatif seimbang (50,7% : 49,3%)	value_counts()	Tidak ada risiko class imbalance signifikan	Tidak perlu penanganan imbalance khusus

Kesiapan Dataset untuk Modeling

Dataset ini belum siap digunakan langsung untuk pemodelan Machine Learning. Sebelum masuk ke tahap modeling, dataset memerlukan tahap Data Preprocessing (Pertemuan 4) yang mencakup: (1) imputasi missing value pada IP_Smt2 dan Kehadiran_Rata2; (2) investigasi dan koreksi invalid value pada IP_Smt1 (>4) dan Kehadiran_Rata2 (>100%); (3) standardisasi kategori Jalur_Masuk yang tidak konsisten penulisannya; (4) investigasi lanjutan terhadap potential outlier pada Jumlah_Mengulang untuk memutuskan apakah nilai tersebut dipertahankan, ditransformasi, atau ditangani dengan cara lain; serta (5) penyesuaian skala antarvariabel numerik (scaling) sebelum digunakan pada algoritma yang sensitif terhadap skala. Distribusi target yang relatif seimbang berarti penanganan class imbalance tidak menjadi prioritas pada tahap preprocessing kali ini.

Lampiran — Jawaban Pertanyaan Analisis Wajib

1. **Variabel apa saja yang memiliki missing value dan berapa jumlahnya?** IP_Smt2 memiliki 6 nilai kosong (2,0%), dan Kehadiran_Rata2 memiliki 3 nilai kosong (1,0%), dari total 300 observasi.

2. **Nilai apa yang teridentifikasi sebagai invalid value?** IP_Smt1 = 4,75 pada MHS0065 (melanggar domain IP yang valid 0–4) dan Kehadiran_Rata2 = 125,0% pada MHS0190 (melanggar domain persentase yang valid 0–100%). Selain itu, kategori Jalur_Masuk memiliki penulisan tidak konsisten ("regular", "REG" yang seharusnya "Reguler").

3. **Apa perbedaan antara invalid value dan potential outlier pada dataset ini?** Invalid value adalah nilai yang secara domain/aturan variabel tidak mungkin terjadi, seperti IP > 4 atau kehadiran > 100% — nilai ini pasti bermasalah terlepas dari analisis statistik apa pun. Potential outlier adalah nilai ekstrem secara statistik (di luar batas IQR) namun masih berada dalam rentang yang mungkin valid secara domain, seperti Jumlah_Mengulang = 7 atau 12 — nilai ini perlu diinvestigasi lebih lanjut, bukan otomatis dianggap salah, karena secara nyata seorang mahasiswa memang bisa mengulang mata kuliah sebanyak itu.

4. **Bagaimana karakteristik mahasiswa Tepat Waktu dibandingkan Tidak Tepat Waktu?** Berdasarkan IP: kelompok Tepat Waktu memiliki rata-rata IP lebih tinggi di semua semester (≈3,32–3,41 vs ≈2,91–2,98). Berdasarkan kehadiran: kelompok Tepat Waktu memiliki kehadiran rata-rata lebih tinggi (90,55% vs 82,54%). Berdasarkan jumlah mengulang: kelompok Tepat Waktu mengulang lebih sedikit mata kuliah (1,12 vs 2,45). Berdasarkan nilai D/E: kelompok Tepat Waktu memiliki jumlah nilai D/E lebih rendah (0,93 vs 1,57). Secara umum, performa akademik dan kehadiran yang lebih baik cenderung berasosiasi dengan kelulusan tepat waktu pada dataset ini, meski terdapat overlap antar-kelompok.

5. **Apakah target Status_Kelulusan mengalami class imbalance?** Tidak. Distribusi target adalah 152 mahasiswa Tepat Waktu (50,7%) dan 148 mahasiswa Tidak Tepat Waktu (49,3%), yang relatif seimbang (mendekati 50:50). Class imbalance signifikan tidak terjadi pada dataset ini.

6. **Sebutkan minimal tiga hubungan pada correlation heatmap dan interpretasinya.** (1) IP_Smt3 dan IP_Smt4 berkorelasi positif kuat (r≈0,69), menunjukkan konsistensi performa antarsemester. (2) Jumlah_Mengulang berkorelasi negatif sedang dengan IP di semua semester (r≈−0,36 s.d. −0,39), mahasiswa yang lebih banyak mengulang cenderung ber-IP lebih rendah. (3) Kehadiran_Rata2 berkorelasi positif sedang-kuat dengan IP (r≈0,55–0,61), kehadiran tinggi cenderung berasosiasi dengan IP yang lebih baik.

7. **Mengapa korelasi tidak boleh langsung diartikan sebagai hubungan sebab-akibat?** Karena korelasi hanya mengukur seberapa kuat dan searah/berlawanan arah pola hubungan linear antara dua variabel pada dataset yang diamati, tanpa memperhitungkan kemungkinan adanya variabel ketiga (confounding factor) yang memengaruhi keduanya, arah kausalitas yang sebenarnya, atau apakah hubungan tersebut kebetulan pada sampel data ini. Untuk menyimpulkan sebab-akibat diperlukan desain penelitian khusus (misalnya eksperimen terkontrol) dan bukti tambahan di luar korelasi deskriptif.

8. **Apakah dataset sudah siap digunakan untuk modeling?** Belum. Dataset masih memerlukan tahap preprocessing sebelum modeling, meliputi: imputasi missing value pada IP_Smt2 dan Kehadiran_Rata2; investigasi/koreksi invalid value pada IP_Smt1 dan Kehadiran_Rata2; standardisasi kategori Jalur_Masuk yang tidak konsisten; investigasi lanjutan terhadap potential outlier pada Jumlah_Mengulang; encoding variabel kategorikal (Jenis_Kelamin, Jalur_Masuk, Status_Kelulusan); dan scaling/normalisasi variabel numerik yang memiliki skala berbeda-beda (IP 0–4, SKS belasan-puluhan, kehadiran 0–100%).